作业5

一、目的

掌握MapReduce编程方法，用MapReduce解决常见的数据处理问题。

二、平台

已经配置完成的Hadoop伪分布式或Docker集群环境。

三、任务说明

对于给定的两个输入文件A和B（如附件所示），文件内包含了纳斯达克100指数、标普500指数、道琼斯工业指数的部分成分股数据，第一列为三大指数编号（简化为101、102、103），第二列为成分股代码。请编写Mapreduce程序，完成以下任务。

任务1：求每个指数下A与B的成分股集合关系

对每个指数编号和股票代码，判断该股票在 `A.txt` 和 `B.txt` 中的出现情况：

- 如果同时出现在 A 和 B 中，标记为 `BOTH`；
- 如果只出现在 A 中，标记为 `A_ONLY`；
- 如果只出现在 B 中，标记为 `B_ONLY`。

输出格式：

```
指数编号	股票代码	关系标记
```

例如：

```
101	JPM	BOTH
101	UNH	BOTH
101	V	BOTH
101	AAPL	A_ONLY
101	KO	B_ONLY
```

任务2：统计每个指数的交集、差集与并集数量

对任务 1 的结果进行二次统计，输出每个指数下：

- 交集数量：BOTH 数量；
- A 独有数量：A_ONLY 数量；
- B 独有数量：B_ONLY 数量；
- 并集数量：BOTH + A_ONLY + B_ONLY。

输出格式：

```
指数编号      交集数量      A独有数量      B独有数量      并集数量
```

例如：

```
101    3    13    4    20
102    3    19    3    25
103    ...    ...    ...    ...
```

四、输入输出要求

输入

两个文本文件：

- `A.txt`
- `B.txt`

每行两列，使用制表符或空格分隔：

```
指数编号 股票代码
```

同一文件中若出现重复股票代码，只计算一次。

输出

建议使用两个输出目录：

1. `output_task1`：保存任务 1 的结果；

2. `output_task2`： 保存任务 2 的统计结果。

输出结果按指数编号升序、股票代码升序排列。

五、提交方式

git仓库地址或者相关文件的zip包，包含源代码和输出文件。git仓库目录组织建议：

```
.(Project Name)
├── src
├── target   (只保留jar文件，并忽略其它无关文件)
├── output
|   └── part-r-00000 (输出结果文件)
├── pom.xml
├── .gitignore
└── README.md (对设计思路，程序运行结果等给出说明，并给出提交作业运行成功的WEB页面截图。可以进一步对性能、扩展性等方面存在的不足和可能的改进之处进行分析。)
```